

TRAVAUX DIRIGÉS N° 1 : Classifieur de Bayes

Stephan CLÉMENÇON <stephan.clemencon@telecom-paris.fr>

Quentin BOUNIOT <quentin.bouniot@telecom-paris.fr>

On se place dans le cadre de la classification binaire. Dans tout le TD, on considère un descripteur aléatoire X à valeurs dans un espace mesurable $\mathcal{X} \subset \mathbb{R}^d$ ($d \in \mathbb{N}^*$) et un label aléatoire Y valant 0 ou 1. La distribution jointe du vecteur (X, Y) est notée P , et la fonction de régression (probabilité a posteriori)

$$\eta : x \in \mathcal{X} \mapsto \mathbb{P}(Y = 1 \mid X = x) \in [0, 1].$$

EXERCICE 1. On considère $\mathcal{X} = [0, 1]$ et P telle que :

- la distribution conditionnelle de X sachant $Y = 0$ est $P_0 = \mathcal{U}([0, \theta])$ où $\theta \in]0, 1[$,
- la distribution conditionnelle de X sachant $Y = 1$ est $P_1 = \mathcal{U}([0, 1])$,
- $p = \mathbb{P}(Y = 1) \in]0, 1[$.

Pour $x \in \mathcal{X}$, donner $\eta(x)$ en fonction de p et θ . Donner l'application numérique pour $\theta = 1/2$.

Correction Exercice 1

Étant donné que les distributions conditionnelles sont uniformes et continues, elles admettent des densités de probabilité. On a donc :

$$f_0 : x \in \mathbb{R} \mapsto \frac{1}{\theta} \mathbb{1}_{[0, \theta]}(x), \quad f_1 : x \in \mathbb{R} \mapsto \mathbb{1}_{[0, 1]}(x).$$

Par conséquent, d'après la formule des probabilités totales, la loi marginale de X (non conditionnelle) admet la densité de probabilité suivante :

$$f_X : x \in \mathbb{R} \mapsto (1 - p)f_0(x) + pf_1(x) = (1 - p)\frac{1}{\theta} \mathbb{1}_{[0, \theta]}(x) + p\mathbb{1}_{[0, 1]}(x).$$

Soit maintenant $x \in [0, 1]$. D'après la formule de Bayes (en densité), on a :

$$\eta(x) = \mathbb{P}(Y = 1 \mid X = x) = \frac{pf_1(x)}{f_X(x)} = \frac{p\mathbb{1}_{[0, 1]}(x)}{(1 - p)\frac{1}{\theta} \mathbb{1}_{[0, \theta]}(x) + p\mathbb{1}_{[0, 1]}(x)}$$

$$\eta(x) = \begin{cases} 1 & \text{si } x \in]\theta, 1] \\ \frac{\theta p}{1 - (1 - \theta)p} & \text{si } x \in [0, \theta] \end{cases}$$

Lorsque $\theta = 1/2$, on obtient :

$$\eta(x) = \begin{cases} 1 & \text{si } x \in]\frac{1}{2}, 1] \\ \frac{p}{2 - p} & \text{si } x \in [0, \frac{1}{2}] \end{cases}$$

EXERCICE 2. On considère $\mathcal{X} = \mathbb{R}_+$ et P telle que :

- la distribution de X est P_X sur $\mathcal{X}$,
- la fonction de régression vaut $\eta(x) = \frac{x}{x + \theta}$ pour tout $x \in \mathcal{X}$, où $\theta > 0$ est fixé.

On note h^* le classifieur de Bayes. Expliciter le classifieur de Bayes dans ce modèle. Montrer ensuite que son risque "0-1" (sa probabilité d'erreur) vaut

$$L(h^*) = \int_{\mathcal{X}} \min(\eta(x), 1 - \eta(x)) dP_X(x).$$

Calculer le risque de Bayes lorsque $P_X = \mathcal{U}([0, \alpha\theta])$ où $\alpha > 1$.

Correction Exercice 2

Le classifieur de Bayes pour des labels binaires est donné par :

$$h^*(x) = \mathbb{1}_{\{\eta(x) > 1/2\}}.$$

Soit $x \in \mathcal{X}$. On a :

$$\eta(x) > 1/2 \iff \frac{x}{x + \theta} > \frac{1}{2} \iff 2x > x + \theta \iff x > \theta.$$

Donc le classifieur de Bayes est donné par :

$$h^*(x) = \mathbb{1}_{\{x > \theta\}}.$$

On peut remarquer que la fonction η étant à valeurs dans $[0, 1]$, on a aussi

$$\eta(x) > 1/2 \iff \eta(x) > 1 - \eta(x).$$

Le risque 0-1 de Bayes est donc donné par :

$$\begin{aligned} L(h^*) &= \mathbb{E}(\mathbb{1}_{\{Y \neq h^*(X)\}}) = \mathbb{E}(\mathbb{1}_{\{Y=1\}} \mathbb{1}_{\{h^*(X)=0\}} + \mathbb{1}_{\{Y=0\}} \mathbb{1}_{\{h^*(X)=1\}}) \\ &= \mathbb{E}(\mathbb{E}(\mathbb{1}_{\{Y=1\}} \mathbb{1}_{\{h^*(X)=0\}} + \mathbb{1}_{\{Y=0\}} \mathbb{1}_{\{h^*(X)=1\}} \mid X)) \quad (\text{espérance totale}) \\ &= \mathbb{E}(\eta(X) \mathbb{1}_{\{h^*(X)=0\}} + (1 - \eta(X)) \mathbb{1}_{\{h^*(X)=1\}}) \quad (\text{définition de } \eta \text{ et } h^* \text{ mesurable par } X) \\ &= \mathbb{E}(\eta(X) \mathbb{1}_{\{\eta(X) \leq 1 - \eta(X)\}} + (1 - \eta(X)) \mathbb{1}_{\{\eta(X) > 1 - \eta(X)\}}) \\ &= \mathbb{E}(\min(\eta(X), 1 - \eta(X))) = \int_{\mathcal{X}} \min(\eta(x), 1 - \eta(x)) dP_X(x). \end{aligned}$$

Lorsque $P_X = \mathcal{U}([0, \alpha\theta])$ avec $\alpha > 1$, on a :

$$\begin{aligned}
L(h^*) &= \int_0^{\alpha\theta} \min(\eta(x), 1 - \eta(x)) \frac{1}{\alpha\theta} dx \\
&= \int_0^\theta \frac{x}{x+\theta} \frac{1}{\alpha\theta} dx + \int_\theta^{\alpha\theta} \frac{\theta}{x+\theta} \frac{1}{\alpha\theta} dx \\
&= \frac{1}{\alpha\theta} \left[\int_0^\theta \frac{x}{x+\theta} dx + \int_\theta^{\alpha\theta} \frac{\theta}{x+\theta} dx \right] \\
&= \frac{1}{\alpha\theta} \left[\int_0^\theta 1 - \frac{\theta}{x+\theta} dx + \int_\theta^{\alpha\theta} \frac{\theta}{x+\theta} dx \right] \\
&= \frac{1}{\alpha\theta} \left[\theta - \int_\theta^{2\theta} \frac{\theta}{x} dx + \int_{2\theta}^{(\alpha+1)\theta} \frac{\theta}{x} dx \right] \quad (\text{changement de variable } x \mapsto x + \theta) \\
&= \frac{1}{\alpha} [1 - \ln(\theta) + \ln((\alpha+1)\theta) - 2 \ln(2\theta)] \\
&= \frac{1}{\alpha} \ln \left(e \frac{\alpha+1}{4} \right).
\end{aligned}$$

EXERCICE 3. Soient des poids $\omega(0), \omega(1) \geq 0$ tels que $\omega(0) + \omega(1) = 1$. On considère le risque de classification pondéré :

$$L_\omega(g) = \mathbb{E} \left(2\omega(Y) \cdot \mathbb{1}_{\{Y \neq g(X)\}} \right), \quad g : \mathcal{X} \rightarrow \{0, 1\}.$$

Donner le classifieur de Bayes et le risque de Bayes pour ce critère. Quel est l'intérêt de considérer un tel critère ?

Correction Exercice 3

Le classifieur de Bayes pour le risque pondéré est par définition le classifieur $g^* : \mathcal{X} \rightarrow \{0, 1\}$ qui minimise le risque pondéré $L_\omega(g)$. On définit l'excès de risque pour un classifieur $g : \mathcal{X} \rightarrow \{0, 1\}$ par rapport au classifieur de Bayes g^* :

$$R_\omega(g) = L_\omega(g) - L_\omega(g^*) \geq 0.$$

Soit $g : \mathcal{X} \rightarrow \{0, 1\}$ un classifieur quelconque. On a :

$$\begin{aligned}
L_\omega(g) &= \mathbb{E} \left(2\omega(Y) \cdot \mathbb{1}_{\{Y \neq g(X)\}} \right) = 2\mathbb{E} \left(\omega(1) \cdot \mathbb{1}_{\{Y=1\}} \mathbb{1}_{\{g(X)=0\}} + \omega(0) \cdot \mathbb{1}_{\{Y=0\}} \mathbb{1}_{\{g(X)=1\}} \right) \\
&= 2\mathbb{E} \left(\mathbb{E} \left(\omega(1) \cdot \mathbb{1}_{\{Y=1\}} \mathbb{1}_{\{g(X)=0\}} + \omega(0) \cdot \mathbb{1}_{\{Y=0\}} \mathbb{1}_{\{g(X)=1\}} \mid X \right) \right) \quad (\text{espérance totale}) \\
&= 2\mathbb{E} \left(\mathbb{1}_{\{g(X)=0\}} \cdot \omega(1) \cdot \eta(X) + \mathbb{1}_{\{g(X)=1\}} \cdot \omega(0) \cdot (1 - \eta(X)) \right) \quad (\text{définition de } \eta) \\
&= 2\mathbb{E} \left(\omega(1) \cdot \eta(X) + (\omega(0)(1 - \eta(X)) - \omega(1)\eta(X)) \mathbb{1}_{\{g(X)=1\}} \right) \quad (\mathbb{1}_{\{g(X)=0\}} = 1 - \mathbb{1}_{\{g(X)=1\}}) \\
&= 2\mathbb{E} \left(\omega(1) \cdot \eta(X) + \mathbb{1}_{\{g(X)=1\}} \cdot (\omega(0) - \eta(X)) \right) \quad (\omega(0) + \omega(1) = 1)
\end{aligned}$$

Donc, l'excès de risque est donné par :

$$R_\omega(g) = 2\mathbb{E} \left[(\omega(0) - \eta(X)) (\mathbb{1}_{\{g(X)=1\}} - \mathbb{1}_{\{g^*(X)=1\}}) \right].$$

Or $\forall x \in \mathcal{X}$, on a $(\omega(0) - \eta(x))(\mathbb{1}_{\{g(x)=1\}} - \mathbb{1}_{\{g^*(x)=1\}}) \geq 0$ ssi :

$$\begin{cases} \omega(0) - \eta(x) \geq 0, \\ \mathbb{1}_{\{g(x)=1\}} - \mathbb{1}_{\{g^*(x)=1\}} \geq 0, \end{cases} \quad \text{ou} \quad \begin{cases} \omega(0) - \eta(x) \leq 0, \\ \mathbb{1}_{\{g(x)=1\}} - \mathbb{1}_{\{g^*(x)=1\}} \leq 0. \end{cases}$$

Cela est satisfait $\forall g$ par $g^* : x \in \mathcal{X} \mapsto \mathbb{1}_{\{\eta(x) > \omega(0)\}}$.

Le risque pondéré de Bayes est donc donné par :

$$\begin{aligned} L_\omega(g^*) &= 2\mathbb{E} \left(\omega(1) \cdot \eta(X) + (\omega(0) - \eta(X)) \mathbb{1}_{\{\eta(X) > \omega(0)\}} \right) \\ &= 2\mathbb{E} \left[(\omega(0) + (\omega(1) - 1)\eta(X)) \mathbb{1}_{\{\eta(X) > \omega(0)\}} + \omega(1)\eta(X) \mathbb{1}_{\{\eta(X) \leq \omega(0)\}} \right] \quad \begin{matrix} 1 = \mathbb{1}_{\eta(X) > \omega(0)} + \\ \mathbb{1}_{\eta(X) \leq \omega(0)} \end{matrix} \\ &= 2\mathbb{E} \left[(1 - \eta(X))\omega(0) \mathbb{1}_{\{\eta(X) > \omega(0)\}} + \omega(1)\eta(X) \mathbb{1}_{\{\eta(X) \leq \omega(0)\}} \right] \\ &= 2\mathbb{E} \left[\omega(0)(1 - \omega(0) - \eta(X) + \omega(0)) \mathbb{1}_{\{\eta(X) > \omega(0)\}} + \omega(1)(\eta(X) + \omega(0) - \omega(0)) \mathbb{1}_{\{\eta(X) \leq \omega(0)\}} \right] \\ &= 2\omega(0)\omega(1) + 2\mathbb{E} \left[(\omega(0) - \eta(X)) \mathbb{1}_{\{\eta(X) > \omega(0)\}} \omega(0) + (\eta(X) - \omega(0)) \mathbb{1}_{\{\eta(X) \leq \omega(0)\}} \omega(1) \right] \\ &= 2\omega(0)\omega(1) - 2\mathbb{E} \left[|\eta(X) - \omega(0)| (\omega(0) \mathbb{1}_{\{\eta(X) > \omega(0)\}} + \omega(1) \mathbb{1}_{\{\eta(X) \leq \omega(0)\}}) \right] \quad |\eta(X) - \omega(0)| < 0 \end{aligned}$$

On retrouve bien le risque de Bayes "0-1" lorsque $\omega(0) = \omega(1) = 1/2$:

$$L(g^*) = \frac{1}{2} - \mathbb{E} \left(\left| \eta(X) - \frac{1}{2} \right| \right).$$

Et en remarquant que $\forall x \in \mathcal{X}, \eta(x) \leq \omega(0)$ ssi $\omega(1)\eta(x) \leq \omega(0)(1 - \eta(x))$, on obtient :

$$L_\omega(g^*) = \mathbb{E} \left(\min(\omega(1)\eta(X), \omega(0)(1 - \eta(X))) \right).$$

L'intérêt de considérer un tel critère est de pouvoir pondérer différemment les erreurs de classification selon la classe. Par exemple, dans un problème médical, il peut être plus coûteux de classer un patient malade comme sain (faux négatif) que l'inverse (faux positif). En ajustant les poids $\omega(0)$ et $\omega(1)$, on peut refléter cette asymétrie dans le risque de classification. Exemple : test de grossesse (en cas de grossesse, on veut éviter les faux négatifs, donc on met un poids plus élevé sur la classe 1).

EXERCICE 4. On considère $X = (T, U, V)$ où T, U, V sont des variables aléatoires réelles i.i.d. de loi exponentielle standard. On pose $Y = \mathbb{1}_{\{T+U+V < \theta\}}$ où $\theta \in \mathbb{R}_+$ est fixé. Calculer le classifieur de Bayes $g^*(T, U)$, lorsque V n'est pas observée, puis calculer son risque "0-1" en fonction de θ .

Correction Exercice 4

Notons $\eta : (t, u) \in \mathbb{R}_+^2 \mapsto \mathbb{P}(Y = 1 \mid T = t, U = u)$ la fonction de régression lorsque V n'est pas observée. Par construction, on a :

$$g^*(t, u) : (t, u) \in \mathbb{R}_+^2 \mapsto \mathbb{1}_{\{\eta(t, u) > 1/2\}}.$$

Soient $t, u \in \mathbb{R}_+$. On a :

$$\begin{aligned} \eta(t, u) &= \mathbb{P}(Y = 1 \mid T = t, U = u) = \mathbb{P}(T + U + V < \theta \mid T = t, U = u) \\ &= \mathbb{P}(V < \theta - t - u) \quad (\text{indépendance}) \\ &= F_1(\theta - t - u) = (1 - e^{-(\theta - t - u)}) \mathbb{1}_{\{t+u < \theta\}}. \quad (\text{V de loi exponentielle standard}) \end{aligned}$$

Ainsi $\eta(t, u) > 1/2$ ssi :

$$\begin{cases} t + u < \theta, \\ 1 - e^{-(\theta-t-u)} > 1/2 \end{cases} \iff \begin{cases} t + u < \theta, \\ t + u < \theta - \ln(2) \end{cases} \iff t + u < \theta - \ln(2).$$

Donc le classifieur de Bayes est donné par $g^*(t, u) = \mathbb{1}_{\{t+u < \theta - \ln(2)\}}$.

Le risque de Bayes associé est donné par :

$$\begin{aligned} L(g^*) &= \mathbb{E}(\mathbb{1}_{\{Y \neq g^*(T, U)\}}) = \mathbb{E}(\eta(T, U)\mathbb{1}_{\{g^*(T, U)=0\}} + (1 - \eta(T, U))\mathbb{1}_{\{g^*(T, U)=1\}}) \\ &= \mathbb{E}(\eta(T, U)\mathbb{1}_{\{T+U \geq \theta - \ln(2)\}} + (1 - \eta(T, U))\mathbb{1}_{\{T+U < \theta - \ln(2)\}}) \\ &= \mathbb{E}\left((1 - e^{-(\theta-T-U)})\mathbb{1}_{\{T+U < \theta\}}\mathbb{1}_{\{T+U \geq \theta - \ln(2)\}} + e^{-(\theta-T-U)}\mathbb{1}_{\{T+U < \theta\}}\mathbb{1}_{\{T+U < \theta - \ln(2)\}}\right) \\ &= \mathbb{E}\left((1 - e^{-(\theta-T-U)})\mathbb{1}_{\{\theta - \ln(2) \leq T+U < \theta\}} + e^{-(\theta-T-U)}\mathbb{1}_{\{T+U < \theta - \ln(2)\}}\right) \end{aligned}$$

Ainsi, on peut réécrire le risque de Bayes comme suit :

$$\begin{aligned} L(g^*) &= \int_{-\infty}^{+\infty} (1 - e^{-(\theta-x)})\mathbb{1}_{\{\theta \geq x \geq \theta - \ln(2)\}}f_2(x)dx + \int_{-\infty}^{+\infty} (e^{-(\theta-x)})\mathbb{1}_{\{x < \theta - \ln(2)\}}f_2(x)dx \\ &= \int_{-\infty}^{+\infty} (1 - e^{-(\theta-x)})\mathbb{1}_{\{\theta \geq x \geq \theta - \ln(2)\}}xe^{-x}\mathbb{1}_{\{x \geq 0\}}dx + \int_{-\infty}^{+\infty} (e^{-(\theta-x)})\mathbb{1}_{\{x < \theta - \ln(2)\}}xe^{-x}\mathbb{1}_{\{x \geq 0\}}dx \end{aligned}$$

Si $\theta \geq \ln(2)$, on a :

$$\begin{aligned} L(g^*) &= \int_{\theta - \ln(2)}^{\theta} (1 - e^{-(\theta-x)})xe^{-x}dx + \int_0^{\theta - \ln(2)} e^{-(\theta-x)}xe^{-x}dx \\ &= \int_{\theta - \ln(2)}^{\theta} xe^{-x}dx - \int_{\theta - \ln(2)}^{\theta} xe^{-\theta}dx + \int_0^{\theta - \ln(2)} xe^{-\theta}dx \\ &= F_2(\theta) - F_2(\theta - \ln(2)) - e^{-\theta} \left[\frac{x^2}{2} \right]_{\theta - \ln(2)}^{\theta} + e^{-\theta} \left[\frac{x^2}{2} \right]_0^{\theta - \ln(2)} \\ &= -(\theta + 1)e^{-\theta} + (\theta - \ln(2) + 1)e^{-(\theta - \ln(2))} - e^{-\theta} \left[\frac{\theta^2}{2} - \frac{(\theta - \ln(2))^2}{2} \right] + e^{-\theta} \left[\frac{(\theta - \ln(2))^2}{2} - 0 \right] \\ &= e^{-\theta} \left[(\theta - \ln(2))^2 - \frac{\theta^2}{2} + \theta - 2\ln(2) + 1 \right] \end{aligned}$$

Si $\theta < \ln(2)$, on a :

$$\begin{aligned} L(g^*) &= \int_0^{\theta} (1 - e^{-(\theta-x)})xe^{-x}dx \\ &= \int_0^{\theta} xe^{-x}dx - \int_0^{\theta} e^{-\theta}xdx \\ &= F_2(\theta) - F_2(0) - e^{-\theta} \frac{\theta^2}{2} \\ &= 1 - (\theta + 1)e^{-\theta} - e^{-\theta} \frac{\theta^2}{2} \end{aligned}$$

Conseils bibliographiques

Vous trouverez ci-dessous quelques points d'entrée utiles pour l'apprentissage automatique :

- Théorique et porté sur les aspects probabilistes : [DGL97]
- Utilitaire et porté sur les aspects pratiques : [HTF13]
- Livre récent porté essentiellement sur l’aspect optimisation : [SSBD14] (et du même auteur sur l’apprentissage en ligne [SS12])
- Méthodes Bayésiennes et modèles graphiques : [MB12]

Références

- [DGL97] L. Devroye, L. Györfi, and G. Lugosi. *A Probabilistic Theory of Pattern Recognition*. Stochastic Modelling and Applied Probability. Springer New York, 1997. 6
- [HTF13] T. Hastie, R. Tibshirani, and J. Friedman. *The Elements of Statistical Learning : Data Mining, Inference, and Prediction*. Springer Series in Statistics. Springer New York, 2013. 6
- [MB12] K.P. Murphy and F. Bach. *Machine Learning : A Probabilistic Perspective*. Adaptive Computation and Machine Learning Series. MIT Press, 2012. 6
- [SS12] S. Shalev-Shwartz. *Online Learning and Online Convex Optimization*. Foundations and Trends in Machine Learning Series. Now Publishers, 2012. 6
- [SSBD14] S. Shalev-Shwartz and S. Ben-David. *Understanding Machine Learning : From Theory to Algorithms*. Cambridge University Press, 2014. 6