

TRAVAUX DIRIG  S N   3 : S  parateurs lin  aires

Stephan CL  MEN  ON <stephan.clemencon@telecom-paris.fr>

Quentin BOUNIOT <quentin.bouniot@telecom-paris.fr>

**EXERCICE 1.** On se place dans le cadre de la classification binaire : soient un descripteur al  atoire  $X$     valeurs dans  $\mathbb{R}$  muni de sa tribu des Bor  liens, et un label al  atoire  $Y$  valant 0 ou 1.

Soit  $\mathcal{G} := \{g : \mathbb{R} \rightarrow \{0, 1\}\}$  l'ensemble des classifieurs adapt  s    ce contexte. L'erreur de classification est d  finie comme l'application  $L : g \in \mathcal{G} \mapsto \mathbb{P}(Y \neq g(X)) \in [0, 1]$  et on note  $L^* := \inf_{g \in \mathcal{G}} L(g)$ .

Dans cet exercice, on s'int  resse    la famille  $\mathcal{G}_0$  des classifieurs lin  aires sur  $\mathbb{R}$  de la forme :

$$g_{(x_0, y_0)} : x \in \mathbb{R} \mapsto \begin{cases} y_0 & \text{si } x \leq x_0, \\ 1 - y_0 & \text{sinon,} \end{cases}$$

avec  $(x_0, y_0) \in \mathbb{R} \times \{0, 1\}$ . L'erreur de classification d'un tel  $g_{(x_0, y_0)}$  est not  e plus simplement  $L(x_0, y_0)$  et on pose  $L_0 := \inf_{(x_0, y_0)} L(x_0, y_0)$ .

1) Exprimer l'erreur de classification d'un   l  ment quelconque de  $\mathcal{G}_0$  en fonction des lois conditionnelles de  $X$  sachant  $Y$ . On utilisera les notations  $F_y(x) := \mathbb{P}\{X \leq x \mid Y = y\}$  pour  $(x, y) \in \mathbb{R} \times \{0, 1\}$  et  $p := \mathbb{P}(Y = 1)$ .

2) En consid  rant les points  $(x_0, y_0) = (-\infty, 0)$  et  $(x_0, y_0) = (-\infty, 1)$ , montrer que  $L_0 \leq \frac{1}{2}$ .

3) Montrer que  $L_0 = \frac{1}{2} - \sup_x \left| p F_1(x) - (1 - p) F_0(x) - p + \frac{1}{2} \right|$ . Simplifier l'expression quand  $p = \frac{1}{2}$ .

**Indication.** Pour tout  $(a, b) \in \mathbb{R}^2$  on peut   crire  $\min(a, b) = \frac{a + b - |a - b|}{2}$ .

4) Montrer que  $L_0 = \frac{1}{2}$  si et seulement si  $L^* = \frac{1}{2}$ .

5) Montrer l'in  galit   de Chebychev-Cantelli : pour toute variable al  atoire r  elle  $Z$  et tout  $t \geq 0$ ,

$$\mathbb{P}(Z - \mathbb{E}(Z) \geq t) \leq \frac{\mathbb{V}(Z)}{\mathbb{V}(Z) + t^2}.$$

6) On note respectivement  $m_y$  et  $\sigma_y^2$  l'esp  rance et la variance de la loi conditionnelle de  $X$  sachant  $Y = y$ , avec  $y \in \{0, 1\}$ . Montrer que :

$$L_0 \leq \left( 1 + \frac{(m_0 - m_1)^2}{(\sigma_0 + \sigma_1)^2} \right)^{-1}.$$

**Indication.** Utiliser l'in  galit   d  montr  e    la question pr  c  dente.

7) Discuter de la performance du minimiseur empirique pris dans la classe  $\mathcal{G}_0$  et des limites des classifieurs lin  aires.

### Correction Exercice 1

1) Soit  $(x, y) \in \mathbb{R} \times \{0, 1\}$ . On a :

$$\begin{aligned} L(x, y) &= \mathbb{P}\{Y \neq g_{(x,y)}(X)\} \\ &= \mathbb{P}(X > x \mid Y = y)\mathbb{P}(Y = y) + \mathbb{P}(X \leq x \mid Y = 1 - y)\mathbb{P}(Y = 1 - y) \end{aligned}$$

Comme  $\mathbb{P}(X > x \mid Y = y) = 1 - F_y(x)$  et  $\mathbb{P}(X \leq x \mid Y = 1 - y) = F_{1-y}(x)$ , on distingue les deux cas  $y = 0$  et  $y = 1$  :

$$\begin{aligned} L(x, 0) &= (1 - F_0(x))(1 - p) + F_1(x)p \\ L(x, 1) &= (1 - F_1(x))p + F_0(x)(1 - p) \end{aligned}$$

En combinant ces deux cas, on peut écrire :

$$\begin{aligned} L(x, y) &= \mathbb{1}_{\{y=0\}} [(1 - F_0(x))(1 - p) + F_1(x)p] + \mathbb{1}_{\{y=1\}} [(1 - F_1(x))p + F_0(x)(1 - p)] \\ &= y [p - pF_1(x) + F_0(x) - pF_0(x)] + (1 - y) [1 - p - F_0(x) + pF_0(x) + pF_1(x)] \\ &= 1 - y + (2y - 1)h(x), \end{aligned}$$

où  $h(x) = p - pF_1(x) + F_0(x) - pF_0(x)$ .

2) Pour  $y \in \{0, 1\}$ , on a  $\lim_{x \rightarrow -\infty} F_y(x) = 0$ , et donc  $\lim_{x \rightarrow -\infty} h(x) = p$ . Par conséquent,

$$\lim_{x \rightarrow -\infty} L(x, y) = 1 - y + (2y - 1)p = \begin{cases} 1 - p & \text{si } y = 0, \\ p & \text{si } y = 1. \end{cases}$$

Ainsi,  $L_0 \leq \min(p, 1 - p) \leq \frac{1}{2}$ .

3) Par définition,

$$\begin{aligned} L_0 &= \inf_{(x,y) \in \mathbb{R} \times \{0,1\}} L(x, y) \\ &= \inf_{x \in \mathbb{R}} \min(L(x, 0), L(x, 1)) \\ &= \inf_{x \in \mathbb{R}} \min(h(x), 1 - h(x)) \\ &= \inf_{x \in \mathbb{R}} \frac{h(x) + (1 - h(x)) - |h(x) - (1 - h(x))|}{2} \\ &= \inf_{x \in \mathbb{R}} \left( \frac{1}{2} - \left| h(x) - \frac{1}{2} \right| \right) \\ &= \frac{1}{2} - \sup_{x \in \mathbb{R}} \left| h(x) - \frac{1}{2} \right|. \end{aligned}$$

En remplaçant  $h(x)$  par son expression, on obtient le résultat demandé.

Lorsque  $p = \frac{1}{2}$ , on a  $h(x) = \frac{1}{2} + \frac{F_0(x) - F_1(x)}{2}$ , d'où :

$$\begin{aligned} L_0 &= \frac{1}{2} - \sup_{x \in \mathbb{R}} \left| \frac{F_0(x) - F_1(x)}{2} \right| \\ &= \frac{1}{2} - \frac{1}{2} \sup_{x \in \mathbb{R}} |F_0(x) - F_1(x)| \end{aligned}$$

$$= \frac{1}{2} (1 - d_{TV}(F_0, F_1)).$$

4) Supposons d'abord que  $L^* = \frac{1}{2}$ . Par définition,  $\mathcal{G}_0 \subset \mathcal{G}$ , donc  $L^* \leq L_0$ . Or, d'après la question 2,  $L_0 \leq \frac{1}{2}$ . Ainsi,  $L_0 = \frac{1}{2}$ .

Supposons maintenant que  $L_0 = \frac{1}{2}$ . D'après la question 2,

$$L_0 = \frac{1}{2} \leq \min(p, 1 - p) \leq \frac{1}{2}.$$

On en déduit que  $p = \frac{1}{2}$ . Puis, d'après la question 3,

$$\begin{aligned} L_0 &= \frac{1}{2} (1 - d_{TV}(F_0, F_1)) = \frac{1}{2} \\ &\iff d_{TV}(F_0, F_1) = 0 \\ &\iff F_0 = F_1 \\ &\iff X \mid Y = 1 \sim X \mid Y = 0. \end{aligned}$$

Alors, pour tout classifieur  $g \in \mathcal{G}$ ,

$$\begin{aligned} L(g) &= \mathbb{P}(Y \neq g(X)) \\ &= \mathbb{P}(Y = 1)\mathbb{P}(g(X) = 0 \mid Y = 1) + \mathbb{P}(Y = 0)\mathbb{P}(g(X) = 1 \mid Y = 0) \\ &= \frac{1}{2}\mathbb{P}(g(X) = 0 \mid Y = 1) + \frac{1}{2}\mathbb{P}(g(X) = 1 \mid Y = 0) \quad (\text{car } p = \frac{1}{2}) \\ &= \frac{1}{2}\mathbb{P}(g(X) = 0 \mid Y = 1) + \frac{1}{2}\mathbb{P}(g(X) = 1 \mid Y = 1) \quad (\text{car } X \mid Y = 1 \sim X \mid Y = 0) \\ &= \frac{1}{2}. \end{aligned}$$

Cela vaut pour tout classifieur  $g \in \mathcal{G}$ , donc  $L^* = \frac{1}{2}$  (en particulier pour le classifieur de Bayes).

Remarque : la dernière partie reste vraie dès que  $X \mid Y = 1$  et  $X \mid Y = 0$  ont la même loi (les données ne différencient pas les étiquettes) et que  $p = \frac{1}{2}$  (les deux étiquettes sont équiprobables).

5) Posons  $Z^* = Z - \mathbb{E}(Z)$ , la version centrée de  $Z$ . Comme  $\mathbb{E}(Z^*) = 0$ , on a

$$t = \mathbb{E}(t - Z^*).$$

On obtient alors :

$$\begin{aligned} \mathbb{E}(t - Z^*) &= \mathbb{E}[(t - Z^*)\mathbb{1}_{\{Z^* < t\}}] + \mathbb{E}[(t - Z^*)\mathbb{1}_{\{Z^* \geq t\}}] \\ &\leq \mathbb{E}[(t - Z^*)\mathbb{1}_{\{Z^* < t\}}] \quad (\text{car } t - Z^* \leq 0 \text{ lorsque } Z^* \geq t). \end{aligned}$$

On applique ensuite l'inégalité de Cauchy-Schwarz au membre de droite :

$$\begin{aligned} t^2 &\leq \mathbb{E}[(t - Z^*)\mathbb{1}_{\{Z^* < t\}}]^2 \\ &\leq \mathbb{E}[(t - Z^*)^2] \mathbb{E}[\mathbb{1}_{\{Z^* < t\}}^2] \\ &= \mathbb{E}[(t - Z^*)^2] \mathbb{P}(Z^* < t) \\ &= \mathbb{E}[t^2 + (Z^*)^2 - 2tZ^*] \mathbb{P}(Z^* < t) \\ &= (t^2 + \mathbb{V}(Z)) \mathbb{P}(Z^* < t), \end{aligned}$$

puisque  $\mathbb{E}(Z^*) = 0$  et  $\mathbb{E}((Z^*)^2) = \mathbb{V}(Z^*) = \mathbb{V}(Z)$ . Finalement,

$$\begin{aligned} \frac{t^2}{\mathbb{V}(Z) + t^2} &\leq \mathbb{P}(Z - \mathbb{E}(Z) < t) \\ \iff \frac{t^2}{\mathbb{V}(Z) + t^2} &\leq 1 - \mathbb{P}(Z - \mathbb{E}(Z) \geq t) \\ \iff \mathbb{P}(Z - \mathbb{E}(Z) \geq t) &\leq \frac{\mathbb{V}(Z)}{\mathbb{V}(Z) + t^2}. \end{aligned}$$

6) Remarquons que si  $m_0 = m_1$ , l'inégalité est immédiate. On peut donc supposer  $m_0 \neq m_1$  et, sans perte de généralité,  $m_0 < m_1$ .

Choisissons  $\Delta_0, \Delta_1 > 0$  tels que  $m_1 - m_0 = \Delta_0 + \Delta_1$ , et considérons le classifieur  $g(m_0 + \Delta_0, 0)$ . On a :

$$\begin{aligned} L(m_0 + \Delta_0, 0) &= pF_1(m_0 + \Delta_0) + (1 - p)(1 - F_0(m_0 + \Delta_0)) \\ &= p\mathbb{P}(X \leq m_0 + \Delta_0 \mid Y = 1) + (1 - p)\mathbb{P}(X > m_0 + \Delta_0 \mid Y = 0) \\ &= p\mathbb{P}(m_1 - X \geq \Delta_1 \mid Y = 1) + (1 - p)\mathbb{P}(X - m_0 > \Delta_0 \mid Y = 0) \\ &\leq p \frac{\sigma_1^2}{\sigma_1^2 + \Delta_1^2} + (1 - p) \frac{\sigma_0^2}{\sigma_0^2 + \Delta_0^2} \quad (\text{par l'inégalité de Chebychev-Cantelli}) \\ &\leq \frac{p}{1 + \frac{\Delta_1^2}{\sigma_1^2}} + \frac{1 - p}{1 + \frac{\Delta_0^2}{\sigma_0^2}}. \end{aligned}$$

En prenant  $\Delta_0 = \frac{m_1 - m_0}{\sigma_0 + \sigma_1} \sigma_0$  et  $\Delta_1 = \frac{m_1 - m_0}{\sigma_0 + \sigma_1} \sigma_1$ , on obtient :

$$L(m_0 + \Delta_0, 0) \leq \frac{p}{1 + \frac{(m_1 - m_0)^2}{(\sigma_0 + \sigma_1)^2}} + \frac{1 - p}{1 + \frac{(m_1 - m_0)^2}{(\sigma_0 + \sigma_1)^2}} = \left(1 + \frac{(m_0 - m_1)^2}{(\sigma_0 + \sigma_1)^2}\right)^{-1}.$$

Par définition de  $L_0$ ,  $L_0 \leq L(m_0 + \Delta_0, 0)$ , ce qui donne l'inégalité souhaitée.

Remarque 1 : on vérifie bien que  $\Delta_0 + \Delta_1 = \frac{m_1 - m_0}{\sigma_0 + \sigma_1} (\sigma_0 + \sigma_1) = m_1 - m_0$ .

Remarque 2 :

$$\begin{aligned} \frac{1}{1 + \frac{(m_1 - m_0)^2}{(\sigma_0 + \sigma_1)^2}} &\leq \frac{1}{2} \iff 1 + \frac{(m_1 - m_0)^2}{(\sigma_0 + \sigma_1)^2} \geq 2 \\ &\iff \frac{(m_1 - m_0)^2}{(\sigma_0 + \sigma_1)^2} \geq 1 \\ &\iff |m_1 - m_0| \geq \sigma_0 + \sigma_1. \end{aligned}$$

7) Rappelons d'abord la définition du risque empirique et quelques résultats :

$$\begin{aligned} L_n(g) &= \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{\{Y_i \neq g(X_i)\}} \\ \hat{g}_n &= \arg \min_{g \in \mathcal{G}_0} L_n(g) \\ L(\hat{g}_n) - L_0 &\leq 2 \sup_{(x, y) \in \mathbb{R} \times \{0, 1\}} |L_n(g) - L(g)| \\ \mathbb{P} \left( \sup_{x \in \mathbb{R}} |L_n(g) - L(g)| > \epsilon \right) &\leq 2e^{-2n\epsilon^2}, \quad \forall \epsilon > 0, y \in \{0, 1\}. \end{aligned}$$

On en déduit :

$$\begin{aligned}\mathbb{P}(L(\hat{g}_n) - L_0 > \epsilon) &\leq \mathbb{P}\left(\sup_{(x,y) \in \mathbb{R} \times \{0,1\}} |L(x, y) - L_n(x, y)| > \frac{\epsilon}{2}\right) \\ &\leq \mathbb{P}\left(\sup_{x \in \mathbb{R}} |L(x, 0) - L_n(x, 0)| > \frac{\epsilon}{2}\right) + \mathbb{P}\left(\sup_{x \in \mathbb{R}} |L_n(x, 1) - L(x, 1)| > \frac{\epsilon}{2}\right) \\ &\leq 4e^{-2n(\epsilon/2)^2}.\end{aligned}$$

Ceci vaut pour toute loi jointe de  $(X, Y)$ .

Remarque : il s'agit toutefois d'un risque relatif, qui dépend aussi du meilleur risque atteignable dans la classe de classifieurs considérée (ici  $\mathcal{G}_0$ ). Si les données ne sont pas séparables par un classifieur linéaire, alors  $L_0$  peut être élevé et le minimiseur du risque empirique ne sera pas performant.