
TRAVAUX DIRIG  S N   4 : Convexification du risque

Stephan CL  MEN  ON <stephan.clemencon@telecom-paris.fr>

Quentin BOUNIOT <quentin.bouniot@telecom-paris.fr>

EXERCICE 1. On se place dans le cadre de la classification binaire : on consid  re un descripteur al  atoire X de loi P_X    valeurs dans $\mathbb{R}^d$ ($d \in \mathbb{N}^*$) muni de sa tribu des Bor  liens, et un label al  atoire Y valant -1 ou 1 .

La fonction de r  gression (probabilit   a posteriori) est not  e $\eta : x \in \mathbb{R}^d \mapsto \mathbb{P}(Y = 1 \mid X = x) \in [0, 1]$. On suppose que $0 < \eta(X) < 1$ presque-s  urement.

Soit $\mathcal{G} := \{g : \mathbb{R}^d \rightarrow \{-1, 1\}\}$ l'ensemble des classifieurs adapt  s    ce contexte. L'erreur de classification est d  finie comme l'application $L : g \in \mathcal{G} \mapsto \mathbb{P}(Y \neq g(X)) \in [0, 1]$ et on note $L^* := \inf_{g \in \mathcal{G}} L(g)$.

On pose $\mathcal{F} := \{f : \mathbb{R}^d \rightarrow \mathbb{R}\}$ puis $\text{sgn} : a \in \mathbb{R} \mapsto 2 \mathbb{1}_{\{a \geq 0\}} - 1 \in \{-1, 1\}$. Dans cet exercice on s'int  resse sp  cifiquement    l'ensemble de classifieurs $\mathcal{G}_{\mathcal{F}} := \{\text{sgn} \circ f : f \in \mathcal{F}\}$.

Soit enfin $\phi : \mathbb{R} \rightarrow \mathbb{R}_+$ une fonction d  rivable, strictement convexe, croissante, satisfaisant $\lim_{x \rightarrow -\infty} \phi(x) = 0$ et $\phi(0) = 1$. Pour tout $f \in \mathcal{F}$ (et donc tout classifieur de $\mathcal{G}_{\mathcal{F}}$) on consid  re la version convexifi  e du risque de classification :

$$A(f) := \mathbb{E} \left[\phi(-Yf(X)) \right].$$

- 1) Pour tout $u \in [0, 1]$ on d  finit $h_u : a \in \mathbb{R} \mapsto u \phi(-a) + (1 - u) \phi(a)$. Montrer que $\min_{f \in \mathcal{F}} A(f)$ est atteint en

$$f^* : x \in \mathbb{R}^d \mapsto \arg \min_{a \in \mathbb{R}} h_{\eta(x)}(a). \quad (1)$$

Cette fonction est-elle bien d  finie pour tout $x \in \mathbb{R}^d$?

- 2) D  river la fonction $h_{\eta(x)}$ pour $x \in \mathbb{R}^d$ quelconque, puis v  rifier que $\text{sgn} \circ f^*$ co  incide avec le classifieur de Bayes.
- 3) (Lemme de Zhang) On pose $H : u \in]0, 1[\mapsto \min_{a \in \mathbb{R}} h_u(a)$ et on suppose qu'il existe des constantes $s > 1$ et $c > 0$ telles que

$$\forall u \in]0, 1[, \quad \left| \frac{1}{2} - u \right|^s \leq c^s (1 - H(u)). \quad (2)$$

- a) Soit $f \in \mathcal{F}$. Montrer que $L(\text{sgn} \circ f) - L^* \leq 2 \left(\mathbb{E} \left[|\eta(X) - 1/2|^s \mathbb{1}_{\{(2\eta(X)-1)f(X) \leq 0\}} \right] \right)^{1/s}$.

- b) On pose $A^* := \inf_{f \in \mathcal{F}} A(f)$. D  duire de la question pr  c  dente que pour toute fonction $f \in \mathcal{F}$,

$$L(\text{sgn} \circ f) - L^* \leq 2c (A(f) - A^*)^{1/s}. \quad (3)$$

- c) Que vaut H dans le cas o   $\phi = \exp$? Pour quelles constantes s et c la condition (2) est-elle v  rifi  e ?

Correction Exercice 1

1) Soit $f \in \mathcal{F}$. On a :

$$\begin{aligned} A(f) &= \mathbb{E} [\phi(-Yf(X))] = \mathbb{E} [\phi(-f(X))\mathbb{1}_{\{Y=1\}} + \phi(f(X))\mathbb{1}_{\{Y=-1\}}] \\ &= \mathbb{E} [\phi(-f(X))\eta(X) + \phi(f(X))(1 - \eta(X))] \quad (\text{espérance totale, en conditionnant par } X) \\ &= \mathbb{E} [h_{\eta(X)}(f(X))] = \int_{\mathbb{R}^d} h_{\eta(x)}(f(x)) \mathbf{P}_X(dx). \end{aligned}$$

Comme $h_{\eta(x)}(f(x)) \geq \min_{a \in \mathbb{R}} h_{\eta(x)}(a) = h_{\eta(x)}(f^*(x))$ pour tout x , par construction, si f^* est bien définie pour $\mathbf{P}_X$ -presque tout x , alors $A(f) \geq A(f^*)$ pour tout $f \in \mathcal{F}$, i.e. f^* minimise effectivement le risque convexifié.

Vérifions maintenant cette condition. Rappelons les hypothèses faites sur la fonction $\phi : \mathbb{R} \rightarrow \mathbb{R}_+$:

- (i) ϕ est dérivable,
- (ii) ϕ est strictement convexe,
- (iii) ϕ est croissante,
- (iv) $\lim_{x \rightarrow -\infty} \phi(x) = 0$,
- (v) $\phi(0) = 1$.

On remarque au passage que $x \mapsto e^x$ satisfait toutes ces hypothèses. On en déduit un certain nombre de propriétés supplémentaires :

- (vi) ϕ est strictement croissante.

Preuve : ϕ est croissante ; si elle n'était pas strictement croissante, elle admettrait au moins un palier, ce qui contredirait la stricte convexité.

- (vii) $\phi > 0$.

Preuve : conséquence immédiate de (iv) et (vi) : pour tout x , $\phi(x) > \phi(x-1) \geq \lim_{-\infty} \phi = 0$.

- (viii) $\phi'(0) > 0$.

Preuve : ϕ étant strictement convexe et dérivable, elle vérifie pour tout $x \neq 0$ l'inégalité $\phi(x) > \phi(0) + \phi'(0)x$ (la courbe représentative de ϕ est strictement au-dessus de sa tangente en 0). Comme ϕ est croissante, $\phi'(0) \geq 0$. Par l'absurde, si on avait $\phi'(0) = 0$, alors pour tout $x < 0$ on obtiendrait $\phi(x) > \phi(0)$, ce qui contredirait la croissance de ϕ . Donc $\phi'(0) > 0$.

- (ix) $\lim_{x \rightarrow +\infty} \phi(x) = +\infty$.

Preuve : comme précédemment, pour tout $x \neq 0$, $\phi(x) > \phi(0) + \phi'(0)x$, et en utilisant (viii) on obtient $\lim_{x \rightarrow +\infty} \phi(x) = +\infty$.

Prenons maintenant $u \in [0, 1]$ et étudions la fonction h_u .

- **Cas** $u \in \{0, 1\}$. Les propriétés (iv) et (vi) impliquent que ϕ n'admet pas de minimum, mais seulement un infimum (égal à 0) atteint en $-\infty$. Ainsi $h_0 : a \mapsto \phi(a)$ et $h_1 : a \mapsto \phi(-a)$ n'admettent pas de minimum, et f^* n'est pas définie sur l'ensemble $\mathcal{X}_0 := \{x \in \mathbb{R}^d : \eta(x) \in \{0, 1\}\}$.
- **Cas** $u \in]0, 1[$. Commençons par remarquer que :
 - (x) $\lim_{a \rightarrow +\infty} h_u(a) = \lim_{a \rightarrow -\infty} h_u(a) = +\infty$, d'après (iv) et (ix) (et car $u > 0$ et $1-u > 0$),
 - (xi) $h_u(0) = 1$, d'après (v),
 - (xii) h_u est continue, car ϕ , donc h_u , est dérivable.

Les points (x) et (xi) impliquent qu'il existe $\alpha > 0$ tel que $h_u(a) > 1 = h_u(0)$ pour tout $a \in]-\infty, -\alpha[\cup]\alpha, +\infty[$. D'après (xii), h_u est continue sur le compact $[-\alpha, \alpha]$: elle y est donc bornée et atteint ses bornes (théorème des bornes atteintes), i.e. elle y admet au moins un minimiseur m_u . De plus, ϕ étant strictement convexe, h_u l'est aussi (combinaison positive de fonctions strictement convexes), donc m_u est unique. Par construction, $h_u(m_u) \leq 1 = h_u(0) < h_u(a)$ pour $|a| > \alpha$, donc m_u est même l'unique minimiseur global de h_u sur $\mathbb{R}$.

Ainsi, f^* est bien définie sur l'ensemble $\mathcal{X}_1 := \{x \in \mathbb{R}^d : \eta(x) \in]0, 1[\}$.

Rappelons-nous enfin que par hypothèse, $\eta(X) \in]0, 1[$ $\mathbf{P}_X$ -p.s., i.e. $\mathbf{P}_X(\mathcal{X}_0) = 0$ et $\mathbf{P}_X(\mathcal{X}_1) = 1$. On en conclut que f^* est bien définie pour $\mathbf{P}_X$ -presque tout $x \in \mathbb{R}^d$ (ce qui suffit, car A ne dépend que des valeurs de f $\mathbf{P}_X$ -p.s.).

2) Soit $x \in \mathbb{R}^d$. Comme ϕ est dérivable (i), la fonction $h_{\eta(x)} : \mathbb{R} \rightarrow \mathbb{R}_+$ l'est aussi, et pour tout $a \in \mathbb{R}$:

$$h'_{\eta(x)}(a) = -\eta(x)\phi'(-a) + (1 - \eta(x))\phi'(a).$$

Vérifions que $\text{sgn} \circ f^*$ coïncide avec le classifieur de Bayes $g^* : x \mapsto 2\mathbb{1}_{\{\eta(x) \geq 1/2\}} - 1$. Prenons pour cela $x \in \mathcal{X}_1$. Nous avons vu qu'alors $h_{\eta(x)}$ est dérivable, strictement convexe, et admet un unique minimiseur en $f^*(x)$. Par conséquent, $h'_{\eta(x)}(a) = 0 \iff a = f^*(x)$. Or $h'_{\eta(x)}(a) = 0$ signifie :

$$\frac{\eta(x)}{1 - \eta(x)} = \frac{\phi'(a)}{\phi'(-a)}.$$

(Comme $x \in \mathcal{X}_1$, on a bien $1 - \eta(x) \neq 0$. De plus, ϕ étant strictement convexe et croissante, sa dérivée est positive ou nulle et strictement croissante sur $\mathbb{R}$, donc strictement positive.) On a donc l'égalité des rapports $\frac{\eta(x)}{1 - \eta(x)} = \frac{\phi'(f^*(x))}{\phi'(-f^*(x))}$, d'où :

$$\begin{aligned} \eta(x) > \frac{1}{2} &\iff \frac{\eta(x)}{1 - \eta(x)} > 1 \iff \frac{\phi'(f^*(x))}{\phi'(-f^*(x))} > 1 \iff \phi'(f^*(x)) > \phi'(-f^*(x)) \\ &\iff f^*(x) > -f^*(x) \iff f^*(x) > 0 \quad (\phi' \text{ strictement croissante}). \end{aligned}$$

Le même raisonnement avec des égalités donne $\eta(x) = \frac{1}{2} \iff f^*(x) = 0$, d'où $\eta(x) \geq \frac{1}{2} \iff f^*(x) \geq 0$. Finalement :

$$\text{sgn} \circ f^*(x) = 2\mathbb{1}_{\{f^*(x) \geq 0\}} - 1 = 2\mathbb{1}_{\{\eta(x) \geq \frac{1}{2}\}} - 1 = g^*(x),$$

pour $\mathbf{P}_X$ -presque tout $x \in \mathbb{R}^d$. La fonction $\text{sgn} \circ f^*$ coïncide effectivement avec le classifieur de Bayes.

3) a) Soit $f \in \mathcal{F}$ et $g = \text{sgn} \circ f$. Nous avons vu à l'exercice 2 du TD2 que :

$$L(g) - L^* = 2\mathbb{E} \left[\left| \eta(X) - \frac{1}{2} \right| \mathbb{1}_{\{g(X) \neq g^*(X)\}} \right] = 2\mathbb{E} \left[\left| \eta(X) - \frac{1}{2} \right| \left| \mathbb{1}_{\{f(X) < 0\}} - \mathbb{1}_{\{\eta(X) < \frac{1}{2}\}} \right| \right].$$

Or, pour tout $x \in \mathbb{R}^d$ tel que $\eta(x) \neq \frac{1}{2}$ (les autres points ne contribuent pas à l'espérance) :

$$\left| \mathbb{1}_{\{f(x) < 0\}} - \mathbb{1}_{\{\eta(x) < \frac{1}{2}\}} \right| = \begin{cases} 0 & \text{si } \text{sgn}(f(x)) = \text{sgn}(2\eta(x) - 1) \\ 1 & \text{sinon} \end{cases} \leq \mathbb{1}_{\{(2\eta(x) - 1)f(x) \leq 0\}}.$$

D'où :

$$L(\text{sgn} \circ f) - L^* \leq 2\mathbb{E} \left[\left| \eta(X) - \frac{1}{2} \right| \mathbb{1}_{\{(2\eta(X) - 1)f(X) \leq 0\}} \right]$$

$$\begin{aligned}
&= 2\mathbb{E} \left[\left(\left| \eta(X) - \frac{1}{2} \right|^s \mathbb{1}_{\{(2\eta(X)-1)f(X) \leq 0\}} \right)^{\frac{1}{s}} \right] \\
&\leq 2 \left(\mathbb{E} \left[\left| \eta(X) - \frac{1}{2} \right|^s \mathbb{1}_{\{(2\eta(X)-1)f(X) \leq 0\}} \right] \right)^{\frac{1}{s}},
\end{aligned}$$

en utilisant l'inégalité de Jensen pour la fonction concave $x \in \mathbb{R}_+ \mapsto x^{1/s}$ (concave car $s > 1$).

b) Par hypothèse, il existe des réels $s > 1$ et $c > 0$ tels que pour tout $u \in]0, 1[$:

$$\left| \frac{1}{2} - u \right|^s \leq c^s (1 - H(u)).$$

Par conséquent, pour tout $x \in \mathcal{X}_1$:

$$\left| \eta(x) - \frac{1}{2} \right|^s \leq c^s (1 - H(\eta(x))),$$

avec $H(\eta(x)) = \min_{a \in \mathbb{R}} h_{\eta(x)}(a) = h_{\eta(x)}(f^*(x))$ d'après la question 1.

Soit maintenant $f \in \mathcal{F}$. En repartant du résultat de la question 3.a, cette dernière inégalité donne :

$$\begin{aligned}
L(\text{sgn} \circ f) - L^* &\leq 2 \left(\mathbb{E} \left[c^s (1 - h_{\eta(X)}(f^*(X))) \mathbb{1}_{\{(2\eta(X)-1)f(X) \leq 0\}} \right] \right)^{\frac{1}{s}} \\
&= 2c \left(\mathbb{E} \left[(1 - h_{\eta(X)}(f^*(X))) \mathbb{1}_{\{(2\eta(X)-1)f(X) \leq 0\}} \right] \right)^{\frac{1}{s}}.
\end{aligned}$$

Puisque la fonction $x \in \mathbb{R}_+ \mapsto x^{1/s}$ est croissante et que $c > 0$, il nous reste à vérifier que $A(f) - A^*$ majore cette dernière espérance.

Nous avons vu en question 1 que $A^* = A(f^*)$, donc $A(f) - A^* = \mathbb{E} [h_{\eta(X)}(f(X)) - h_{\eta(X)}(f^*(X))]$. Prenons maintenant $x \in \mathcal{X}_1$.

— Si $(2\eta(x) - 1)f(x) > 0$, alors par définition de f^* :

$$(1 - h_{\eta(x)}(f^*(x))) \mathbb{1}_{\{(2\eta(x)-1)f(x) \leq 0\}} = 0 \leq h_{\eta(x)}(f(x)) - h_{\eta(x)}(f^*(x)).$$

— Si $(2\eta(x) - 1)f(x) \leq 0$, alors :

$$\begin{aligned}
h_{\eta(x)}(f(x)) &= \eta(x)\phi(-f(x)) + (1 - \eta(x))\phi(f(x)) && \text{(définition de } h_{\eta(x)}) \\
&\geq \phi(-\eta(x)f(x) + (1 - \eta(x))f(x)) && (\phi \text{ convexe}) \\
&= \phi(-f(x)(2\eta(x) - 1)) \\
&\geq \phi(0) && (\phi \text{ croissante et } -f(x)(2\eta(x) - 1) \geq 0) \\
&= 1 && (\text{par (v)}),
\end{aligned}$$

puis :

$$h_{\eta(x)}(f(x)) - h_{\eta(x)}(f^*(x)) \geq 1 - h_{\eta(x)}(f^*(x)) = (1 - h_{\eta(x)}(f^*(x))) \mathbb{1}_{\{(2\eta(x)-1)f(x) \leq 0\}}.$$

Nous avons donc démontré que, $\mathbf{P}_X$ -p.s. :

$$h_{\eta(X)}(f(X)) - h_{\eta(X)}(f^*(X)) \geq (1 - h_{\eta(X)}(f^*(X))) \mathbb{1}_{\{(2\eta(X)-1)f(X) \leq 0\}},$$

et l'inégalité reste vraie en passant à l'espérance des deux côtés. In fine, nous avons bien montré que :

$$L(\text{sgn} \circ f) - L^* \leq 2c (A(f) - A^*)^{1/s}.$$

c) Soient $\phi : x \in \mathbb{R} \mapsto e^x$ et $u \in]0, 1[$. Alors pour tout $a \in \mathbb{R}$, $h_u(a) = ue^{-a} + (1-u)e^a$, et $h'_u(a) = -ue^{-a} + (1-u)e^a$. Ainsi h_u atteint son minimum en $a_u \in \mathbb{R}$ tel que :

$$\frac{u}{1-u} = \frac{e^{a_u}}{e^{-a_u}} = e^{2a_u}, \quad \text{i.e. en } a_u = \frac{1}{2} \ln \left(\frac{u}{1-u} \right),$$

et :

$$h_u(a_u) = u\sqrt{\frac{1-u}{u}} + (1-u)\sqrt{\frac{u}{1-u}} = 2\sqrt{u}\sqrt{1-u}.$$

La fonction H s'écrit alors $H : u \in]0, 1[\mapsto 2\sqrt{u(1-u)}$. Elle est dérivable, de dérivée $H' : u \in]0, 1[\mapsto \frac{1-2u}{\sqrt{u(1-u)}}$, amenant au tableau de variations suivant :

u	0	$\frac{1}{2}$	1		
$H'(u)$		+	0	-	
$H(u)$	0	$\nearrow$	1	$\searrow$	0

On remarque alors que pour tout $u \in]0, 1[$, $\sqrt{u}\sqrt{1-u} \leq \frac{1}{2}$, d'où :

$$\begin{aligned} 1 - H(u) &= 1 - 2\sqrt{u}\sqrt{1-u} = 2 \left(\frac{1}{2} - \sqrt{u}\sqrt{1-u} \right) \\ &\geq 2 \left(\frac{1}{2} - \sqrt{u}\sqrt{1-u} \right) \left(\frac{1}{2} + \sqrt{u}\sqrt{1-u} \right) \quad (\text{le dernier facteur est } \leq 1, \text{ le premier est } \geq 0) \\ &= 2 \left(\frac{1}{4} - u(1-u) \right) = 2 \left(\frac{1}{4} + u^2 - u \right) \\ &= 2 \left(\frac{1}{2} - u \right)^2, \end{aligned}$$

qui donne finalement :

$$\left| \frac{1}{2} - u \right|^2 \leq \frac{1}{2} (1 - H(u)).$$

Les constantes $s = 2$ et $c = \frac{1}{\sqrt{2}}$ permettent donc de vérifier la condition (2). Pour la perte exponentielle (utilisée dans AdaBoost), on obtient alors :

$$L(\text{sgn} \circ f) - L^* \leq \sqrt{2} (A(f) - A^*)^{1/2}.$$